

**ANALISIS SENTIMEN OPINI PUBLIK MENGENAI ISU
MELEMAHNYA RUPIAH MENGGUNAKAN KOMPARASI
ALGORITMA NAIVE BAYES DAN SVM (STUDI KASUS:
KOMENTAR VIDEO YOUTUBE FERRY IRWANDI)”**



Ahmad Fauzan Ar-Rafi'i



YouTube

ferry irwandi

×

Q



Mengapa Rupiah Terus Melemah?

Ferry Irwandi

2,35 jt subscriber

Gabung

Subscribe

71 rb

Bagikan

Tanya

Download

2,8 jt x ditonton 3 minggu yang lalu 1 produk

Kenapa nilai Rupiah terus melemah?

Di video ini kita bahas apa penyebab Rupiah turun, dampaknya ke kehidupan sehari-hari, dan kenapa kondisi ekonomi global ikut mempengaruhi Indonesia. Singkat, padat, dan mudah dipahami.

...selengkapnya


10.077 Komentar

Urutkan

1. YouTube merupakan salah satu platform yang memungkinkan pengguna memberikan opini melalui kolom komentar.
2. Video "Mengapa Rupiah Terus Melemah?" karya Ferry Irwandi ditonton lebih dari 1 juta views dan memperoleh ribuan komentar yang mencerminkan berbagai tanggapan dan pandangan masyarakat terhadap isu ekonomi yang dibahas.
3. Pelemahan nilai tukar rupiah menjadi isu yang penting untuk dibahas karena dapat memengaruhi berbagai aspek perekonomian, Selain itu, perubahan nilai tukar rupiah juga sering dijadikan indikator kondisi ekonomi suatu negara.

Tujuan

Tujuan utama proyek ini adalah menerapkan tahapan Data Science secara lengkap, mulai dari pengumpulan data, pemahaman data, pembersihan data, pelabelan data, ekstraksi fitur, pembangunan model machine learning, hingga evaluasi model. Analisis sentimen pada komentar YouTube dipilih karena menyediakan data teks dalam jumlah besar yang dapat digunakan untuk mengukur opini masyarakat terhadap suatu isu yang sedang hangat diperbincangkan, yaitu pelemahan nilai tukar Rupiah.



Data Understanding

Sumber Data

- Platform: YouTube
- Channel: Ferry Irwandi
- Video: Mengapa Rupiah Terus Melemah?

Metode Pengambilan Data

- Data diperoleh menggunakan tools YouTube Comment Downloader yang kemudian diekspor ke format CSV.

Jumlah Data


- Sebanyak 4996 komentar utama berhasil dikumpulkan.

Karakteristik Data

- Data berbentuk teks komentar.
- Berbahasa Indonesia.
- Mengandung emoji, tanda baca, URL, dan karakter khusus.
- Memiliki berbagai opini terkait isu pelemahan Rupiah.

Penilaian Kelayakan Data

- Jumlah data cukup untuk analisis sentimen.
- Data relevan dengan tujuan penelitian karena berisi tanggapan langsung dari penonton terhadap topik yang dibahas.




```

from google.colab import files
import io
import pandas as pd

# 1. UNTUK UPLOAD FILE
uploaded = files.upload()

# 2. AMBIL NAMA FILE
nama_file = list(uploaded.keys())[0]

# 3. JALANKAN KODE MEMBACA CSV
data = pd.read_csv(io.BytesIO(uploaded[nama_file]), sep=';', skiprows=4)

# 4. TAMPILKAN DATA
data.head(5)

```

S.No	Name (click to view profile)	Date	Likes	Comment	(view source)
0	1 =HYPERLINK("http://www.youtube.com/@ferryirwan...")	2026-05-13T07:53:03Z	3855	hallo warga sipil sekalian semoga ini menjelas...	=HYPERLINK("https://www.youtube.com/watch?v=2F...")

Pada tahap ini untuk memuat format csv pada dokumen kedalam dataframe biar mudah dilihat, digunakan library Pandas untuk membaca dan mengelola dataset, NumPy sebagai library pendukung pengolahan numerik, serta io untuk membaca file hasil upload. Dataset kemudian dibaca menggunakan fungsi `read_csv()` dan ditampilkan menggunakan `head()` untuk memastikan struktur data dan isi dataset telah sesuai sebelum memasuki tahap data cleaning.

```
data.shape
```

```
(4996, 6)
```

Pada tahap ini bertujuan untuk mengetahui jumlah row dan colum pada dataset

```
data.dtypes
```

Menampilkan tipe data (data type) dari setiap kolom dalam dataset.

S.No	int64
Name (click to view profile)	object
Date	object
Likes	int64
Comment	object
(view source)	object

```
# === CRITERIA 2: ANALISIS KARAKTERISTIK & STATISTIK DESKRIPTIF DASAR ===
```

```
# Tampilkan informasi ringkas struktur kolom dan missing values
```

```
print("--- Informasi Struktur Data ---")
```

```
data.info()
```

```
# Tampilkan statistik deskriptif untuk kolom numerik (seperti kolom 'Likes')
```

```
print("\n--- Ringkasan Statistik Dasar (Kolom Numerik) ---")
```

```
print(data.describe())
```

Data columns (total 5 columns):

#	Column	Non-Null Count	Dtype
0	S.No	4996 non-null	int64
1	Name (click to view profile)	4996 non-null	object
2	Date	4996 non-null	object
3	Likes	4996 non-null	int64
4	(view source)	4996 non-null	object

dtypes: int64(2), object(3)

memory usage: 234.2+ KB

--- Ringkasan Statistik Dasar (Kolom Numerik) ---

	S.No	Likes
count	4996.000000	4996.000000
mean	2498.500000	2.210168
std	1442.365303	63.404782
min	1.000000	0.000000
25%	1249.750000	0.000000
50%	2498.500000	0.000000
75%	3747.250000	0.000000
max	4996.000000	3855.000000

1. Disini data.info() untuk memahami struktur dataset dan mendeteksi apakah terdapat data yang hilang (missing values).
2. dan data.describe() untuk menampilkan statistik deskriptif dasar pada atribut numerik untuk memahami karakteristik dan sebaran data.


```
# Mengubah kolom 'Date' dari tipe object menjadi datetime
data['Date'] = pd.to_datetime(data['Date'], errors='coerce')

# Verifikasi ulang untuk memastikan tipenya sudah berubah
print("--- Tipe Data Kolom Setelah Dikonversi ---")
print(data['Date'].dtypes)

--- Tipe Data Kolom Setelah Dikonversi ---
datetime64[ns, UTC]
```

Mengubah kolom Date dari tipe teks (object) menjadi tipe tanggal (datetime) agar dapat digunakan dalam analisis berbasis waktu.

Analisis Tren Komentar Berdasarkan Tanggal

```
import matplotlib.pyplot as plt
import seaborn as sns

# =====
# 1. AMBIL BAGIAN TANGGALNYA SAJA (TANPA JAM/ZONA WAKTU)
# =====
# Convert the 'Date' column in data_bersih to datetime objects
data_bersih['Date'] = pd.to_datetime(data_bersih['Date'], errors='coerce')

# Kita gunakan .dt.date untuk mengelompokkan data berdasarkan hari
data_bersih['Tanggal'] = data_bersih['Date'].dt.date (function).iloc: Any

# Hitung jumlah komentar per tanggal, lalu urutkan berdasarkan kronologi tanggal
tren_tanggal = data_bersih['Tanggal'].value_counts().sort_index().reset_index()
tren_tanggal.columns = ['Tanggal', 'Jumlah_Komentar']

# =====
# 2. MEMBUAT VISUALISASI GRAFIK GARIS (LINE CHART)
# =====
plt.figure(figsize=(12, 6))

# Membuat grafik garis dengan titik (marker) di setiap tanggal
sns.lineplot(x='Tanggal', y='Jumlah_Komentar', data=tren_tanggal,
            marker='o', markersize=6, linewidth=2.5, color='#e74c3c')


# Mengatur Estetika Grafik
plt.title('Tren Volume Komentar Netizen Berdasarkan Tanggal', fontsize=14, fontweight='bold',
plt.xlabel('Tanggal Mengunggah Komentar', fontsize=11)
plt.ylabel('Total Komentar per Hari', fontsize=11)
plt.grid(True, linestyle='--', alpha=0.6)


# Memutar teks tanggal di sumbu X agar tidak saling bertabrakan
plt.xticks(rotation=45)
```

```
# Menampilkan angka jumlah komentar tepat di atas titik koordinat (opsional, jika data tidak terlalu padat)
for i in range(len(tren_tanggal)):
    plt.annotate(f"{tren_tanggal['Jumlah_Komentar'].iloc[i]}",
                (tren_tanggal['Tanggal'].iloc[i], tren_tanggal['Jumlah_Komentar'].iloc[i]),
                textcoords="offset points",
                xytext=(0, 8),
                ha='center', fontsize=8, fontweight='bold', color='#2c3e50')

plt.tight_layout()
plt.show()
```

Pada tahap visualisasi data, dilakukan analisis tren komentar berdasarkan tanggal unggah komentar. Data tanggal terlebih dahulu dikonversi ke format datetime dan dikelompokkan berdasarkan hari. Selanjutnya dihitung jumlah komentar per tanggal dan divisualisasikan menggunakan grafik garis. Visualisasi ini bertujuan untuk melihat pola aktivitas penonton serta mengetahui periode dengan volume komentar tertinggi dan terendah.





Data Preparation

Data Cleaning

```
# === CRITERIA 5: PEMBERSIHAN DATA KOTOR (DATA CLEANING) ===

# 1. Menghapus komentar yang duplikat (Spam)
data_bersih = fitur_terpilih.drop_duplicates(subset=['Comment'])

# 2. Menghapus komentar yang kosong (Missing Value)
data_bersih = data_bersih.dropna(subset=['Comment'])

# 3. Membuat salinan data yang aman
data_bersih = data_bersih.copy()

print("--- Hasil Proses Pembersihan Data ---")
print(f"Jumlah baris awal sebelum cleaning : {fitur_terpilih.shape[0]}")
# Assign data_clean before using it in the f-string
data_clean = data_bersih.shape[0]
print(f"Jumlah baris setelah cleaning      : {data_clean}")
print(f"Jumlah data kotor/spam yang dibuang : {fitur_terpilih.shape[0] - data_bersih.shape[0]}")

# Validasi akhir untuk membuktikan keunikan kolom target kepada asesor
print(f"\nApakah kolom 'Comment' sekarang sudah bersih dan 100% unik? {data_bersih['Comment'].is_unique}")
```

```
--- Hasil Proses Pembersihan Data ---
Jumlah baris awal sebelum cleaning : 4996
Jumlah baris setelah cleaning      : 4957
Jumlah data kotor/spam yang dibuang : 39
```

```
Apakah kolom 'Comment' sekarang sudah bersih dan 100% unik? True
```

Tahap data cleaning dilakukan untuk meningkatkan kualitas data dengan menghilangkan data yang tidak relevan, Penghapusan duplikasi bertujuan menghindari bias analisis akibat komentar yang berulang, sedangkan penghapusan missing value dilakukan karena komentar kosong tidak mengandung informasi yang dapat dianalisis. Setelah proses cleaning selesai, dilakukan validasi untuk memastikan seluruh komentar telah unik dan dataset siap digunakan pada tahap berikutnya.

Data Cleaning

=== CRITERIA 6: REPRESENTASI FITUR & REKAYASA FITUR (TEXT PREPROCESSING) ===

```
import re

def rekayasa_fitur_teks(teks):
    # 1. Case Folding: Mengubah huruf menjadi kecil semua
    teks = teks.lower()

    # 2. Menghapus URL / Link Website jika ada
    teks = re.sub(r'http\S+|www\S+|https\S+', '', teks)

    # 3. Menghapus Hashtag (#kata) dan Mention (@kata)
    teks = re.sub(r'#\w+|@\w+', '', teks)

    # 4. Menghapus Angka, Tanda Baca, Simbol, dan Emoji
    # Kode di bawah ini hanya mengizinkan huruf kecil a-z dan spasi biasa
    teks = re.sub(r'^[a-z\s]', '', teks)

    # 5. Menghapus spasi berlebih di awal, tengah, atau akhir teks
    teks = teks.strip()
    teks = re.sub(r'\s+', ' ', teks)
```

```
return teks
```

```
# Terapkan rekayasa fitur untuk membuat kolom teks baru yang sudah bersih total
data_bersih['Clean_Comment'] = data_bersih['Comment'].apply(rekayasa_fitur_teks)
```

```
# Menghapus baris yang mungkin jadi kosong setelah simbol/emojinya dibuang semua
data_bersih = data_bersih[data_bersih['Clean_Comment'] != ''].copy()
```

```
print("--- Hasil Rekayasa Fitur Teks ---")
```

```
# =====
# AGAR TABEL RAPI, LEBAR TERBATAS, DAN OTOMATIS WRAP TEXT (PINDAH BARIS)
# =====
```

```
# 1. Mengatur agar teks di dalam kolom tidak dipotong (...) oleh Pandas
pd.set_option('display.max_colwidth', None)
```

```
# 2. Menampilkan 5 data teratas dengan gaya visualisasi HTML bertipe 'left' (Rata Kiri)
# dan menyisipkan properti CSS untuk membatasi lebar kolom maksimal 400 pixel.
```

```
data_bersih[['Comment', 'Clean_Comment']].head(5).style.set_properties(**{
    'text-align': 'left',
    'max-width': '400px',
    'white-space': 'normal',
    'vertical-align': 'top'
```

--- Hasil Rekayasa Fitur Teks ---

	Comment	Clean_Comment
0	hallo warga sipil sekalian semoga ini menjelaskan ya ❤️	hallo warga sipil sekalian semoga ini menjelaskan ya
1	Entah kenapa hati kecil berkata seorang Ferry Irwandi masih lebih capable buat urus negara ini ketiban Presiden yg ada sekarang.. 🤔	entah kenapa hati kecil berkata seorang ferry irwandi masih lebih capable buat urus negara ini ketiban presiden yg ada sekarang
2	Kekliruan hutang terlalu besar era Jokowi sekarang kena dampaknya, whoosh, IKN,MBG semua program JOKOWI	kekliruan hutang terlalu besar era jokowi sekarang kena dampaknya whoosh iknmbg semua program jokowi

Pada tahap rekayasa fitur dilakukan text preprocessing untuk mengubah komentar mentah menjadi teks yang lebih bersih dan terstruktur. Proses yang dilakukan meliputi case folding, penghapusan URL, hashtag, mention, angka, simbol, emoji, serta spasi berlebih. Hasil preprocessing disimpan pada kolom Clean_Comment dan digunakan sebagai input pada tahap pemodelan machine learning.

Data Labelling

```
# === CRITERIA 7 & 8: PELABELAN DATA SESUAI SOP & MEMBANGUN ALGORITMA PEMODELAN ===
import numpy as np
```

1. Menetapkan SOP Pelabelan Aturan Sederhana (Rule-Based Sentimen)

```
def algoritma_sentimen_sederhana(teks):
    # Kamus kata kunci bermuatan emosi
    kata_positif = ['bagus', 'baik', 'keren', 'mantap', 'hebat', 'luar', 'biasa',
                    'setuju', 'benar', 'tepat', 'pintar', 'cerdas', 'jenius',
                    'sukses', 'berhasil', 'maju', 'berkembang', 'sejahtera',
                    'optimis', 'harapan', 'solusi', 'dukung', 'mendukung',
                    'bangga', 'senang', 'suka', 'salut', 'kece', 'top', 'jos',
                    'valid', 'jelas', 'paham', 'ngerti', 'informatif', 'edukasi',
                    'bermanfaat', 'manfaat', 'capable', 'kompeten', 'ahli',
                    'bijak', 'logis', 'relevan', 'akurat', 'transparan', 'jujur',
                    'amanah', 'stabil', 'kuat', 'menguat', 'surplus', 'untung',
                    'profit', 'investasi', 'ekspor', 'hilirisasi', 'pertumbuhan',
                    'tumbuh', 'efisien', 'produktif', 'inovasi', 'berkualitas',
                    'meningkat', 'naik', 'devisa', 'modal', 'dukung', 'support',
                    'semangat', 'lanjut', 'konsisten']
```

```
    skor = 0
    for kata in kata_positif:
        if kata in teks:
            skor += 1
    for kata in kata_negatif:
        if kata in teks:
            skor -= 1

    # Keputusan Label berdasarkan Skor Polaritas
    if skor > 0:
        return 'Positif'
    elif skor < 0:
        return 'Negatif'
    else:
        return 'Netral'

# 2. Menjalankan Algoritma Pemodelan pada Dataset
data_bersih['Sentiment_Model'] = data_bersih['Clean_Comment'].apply(algoritma_sentimen_sederhana)

print("--- Hasil Proses Pelabelan & Pemodelan Klasifikasi ---")
# Menampilkan contoh hasil pelabelan model terhadap teks bersih
data_bersih[['Clean Comment', 'Sentiment Model']].head(5)
```

```
kata_negatif = [ 'jelek', 'stop', 'koruptor', 'korupsi', 'anak', 'becus', 'otak', 'prabowo', 'jokowi', 'buruk', 'gagal', 'salah', 'rugi'
                  'bodoh', 'owo', 'dollar', 'duit', 'asing', 'gas', 'rakyat', 'pajak', 'rupiah', 'wowo', 'goblok', 'tolol', 'idiot', 'dungu', 'bego',
                  'payah', 'parah', 'kacau', 'amburadul', 'semrawut',
                  'maling', 'rampok', 'dolar', 'ekonomi', 'uang', 'mbg', 'omon', 'lemah', 'korup', 'korupsi', 'manipulasi',
                  'bohong', 'dusta', 'tipu', 'penipu', 'pembohong', 'negara',
                  'hancur', 'bobrok', 'rusak', 'busuk', 'bangkrut',
                  'kolaps', 'bubar', 'ambruk', 'tenggelam', 'ekonomi', 'warga', 'wo',
                  'kecewa', 'sedih', 'marah', 'kesal', 'benci', 'muak',
                  'jijik', 'malu', 'takut', 'khawatir', 'cemas', 'resah',
                  'pesimis', 'melemah', 'lemah', 'defisit', 'utang', 'hutang',
                  'inflasi', 'phk', 'pengangguran', 'resesi', 'krisis',
                  'miskin', 'sengsara', 'menderita', 'berat', 'anjlok',
                  'terpuruk', 'terjepit', 'beban', 'mahal', 'membengkak',
                  'pecat', 'tersangka', 'lengser', 'ogah', 'menolak',
                  'protes', 'tolak', 'ingkar', 'khianat', 'pengkhianat',
                  'pemborosan', 'unfaedah', 'dipaksakan', 'pencitraan',
                  'merampok', 'perampokan', 'menjijikan', 'tong', 'kosong']
```

Pada tahap ini digunakan metode Ruke based Sentiment dg pendekatan Lexicon-Based Sentiment Analysis, yaitu metode analisis sentimen berbasis kamus kata positif dan negatif. Algoritma bekerja dengan memberikan skor pada setiap kata yang ditemukan dalam komentar. Skor positif akan menambah nilai sentimen, sedangkan skor negatif akan mengurangi nilai sentimen. Total skor kemudian digunakan untuk menentukan kategori sentimen Positif, Negatif, atau Netral.

--- Hasil Proses Pelabelan & Tabel Pembobotan Skor ---					
	Clean_Comment	Bobot_Positif	Bobot_Negatif	Skor_Total	Sentiment_Model
0	hallo warga sipil sekalian semoga ini menjelaskan ya	1	1	0	Netral
	entah kenapa hati kecil berkata	1	1	0	Netral
1	seorang ferry irwandi masih lebih capable buat urus negara ini ketiban presiden yg ada sekarang				

Hasil Labelling

```
# === CRITERIA 9: MENILAI KELUARAN PENGUJIAN MODEL (EVALUATION & VISUALIZATION) ===
import seaborn as sns
import matplotlib.pyplot as plt

# 1. Menampilkan Distribusi Frekuensi Hasil Klasifikasi Model
print("--- Hasil Evaluasi Volume Sebaran Model Analisis Sentimen ---")
print(data_bersih['Sentiment_Model'].value_counts())


# 2. Visualisasi Grafik Batang (Bar Chart) untuk Evaluasi Distribusi
plt.figure(figsize=(8, 5))
sns.countplot(x='Sentiment_Model', data=data_bersih, palette='coolwarm', order=['Positif', 'Netral', 'Negatif'])


# Mengatur Estetika Grafik
plt.title("Grafik Evaluasi Distribusi Analisis Sentimen Komentar YouTube", fontsize=12, fontweight='bold')
plt.xlabel("Kategori Klasifikasi Sentimen")
plt.ylabel("Volume / Jumlah Komentar")
plt.grid(axis='y', linestyle='--', alpha=0.5)

# Tampilkan Grafik
plt.show()
```

Pada tahap evaluasi dilakukan analisis distribusi hasil klasifikasi sentimen yang dihasilkan oleh metode Lexicon-Based Sentiment Analysis. Evaluasi dilakukan dengan menghitung jumlah komentar pada masing-masing kategori sentimen dan memvisualisasikannya dalam bentuk grafik batang. Hasil ini digunakan untuk mengetahui kecenderungan opini masyarakat terhadap topik yang dibahas dalam video.

```
--- Hasil Evaluasi Volume Sebaran Model Analisis Sentimen ---
Sentiment_Model
Negatif      2630
Netral       1579
Positif       715
Name: count, dtype: int64
```



A decorative frame surrounds the central text. It consists of thin black lines forming a rectangular border with slightly irregular, hand-drawn corners. At the top-left corner, there is a leafy branch motif. At the top-right corner, there are two small four-pointed stars. At the bottom-left corner, there are two small four-pointed stars. At the bottom-right corner, there is a leafy branch motif.

Modelling & Evaluation

Persiapan Pemodelan (Feature Extraction & Data Splitting)

```
# === TAHAP PERSIAPAN MODELLING: VEKTORISASI & PEMBAGIAN DATA ===  
from sklearn.model_selection import train_test_split  
from sklearn.feature_extraction.text import TfidfVectorizer  
  
# 1. Mengubah Teks Bersih Menjadi Matriks Angka menggunakan Vektor TF-IDF  
tfidf = TfidfVectorizer(max_features=2500)  
X = tfidf.fit_transform(data_bersih['Clean_Comment'])  
y = data_bersih['Sentiment_Model'] # Kolom target label hasil pembobotan sebelumnya  
  
# 2. Membagi Data: 80% untuk Training (Belajar) dan 20% untuk Testing (Ujian Model)  
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)  
  
print("--- Status Kesiapan Dimensi Data ---")  
print(f"Jumlah baris data Training (80%): {X_train.shape[0]} sampel")  
print(f"Jumlah baris data Testing (20%): {X_test.shape[0]} sampel")  
  
--- Status Kesiapan Dimensi Data ---  
Jumlah baris data Training (80%): 3939 sampel  
Jumlah baris data Testing (20%): 985 sampel
```

Pada tahap persiapan pemodelan, data teks yang telah dibersihkan diubah menjadi representasi numerik menggunakan metode TF-IDF. Data latih digunakan untuk melatih model agar dapat mempelajari pola hubungan antara fitur TF-IDF dan label sentimen. Sedangkan data uji digunakan untuk mengevaluasi kemampuan model dalam mengklasifikasikan data baru yang belum pernah dilihat sebelumnya. Pada penelitian ini digunakan pembagian data sebesar 80% untuk training dan 20% untuk testing. Nilai 2500 fitur yg digunakan merupakan parameter yang ditentukan untuk membatasi jumlah fitur atau kata yang digunakan oleh model. Tujuannya adalah mengurangi dimensi data, mempercepat proses komputasi, dan mengurangi noise dari kata-kata yang jarang muncul.

Modeling Naive Bayes

```
# === CRITERIA 8 & 9: ALGORITMA MULTINOMIAL NAIVE BAYES ===
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import classification_report, accuracy_score, confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt

# 1. Membangun & Melatih Algoritma Naive Bayes
model_nb = MultinomialNB()
model_nb.fit(X_train, y_train) # Proses Belajar dari Data Latih (80%)

# 2. Menguji Model pada Data Testing yang Belum Pernah Dilihat (20%)
prediksi_nb = model_nb.predict(X_test) # Proses Menebak

# 3. Menampilkan Metrik Kesuksesan Hasil Pengujian
print("=====")
print("  HASIL EVALUASI METRIK KESUKSESAN ALGORITMA NAIVE BAYES")
print("=====")
print(f"Akurasi Keseluruhan Model: {accuracy_score(y_test, prediksi_nb) * 100:.2f}%")
print("\nLaporan Klasifikasi Detail (Precision, Recall, F1-Score):")
print(classification_report(y_test, prediksi_nb))
```

```
=====
  HASIL EVALUASI METRIK KESUKSESAN ALGORITMA NAIVE BAYES
=====
Akurasi Keseluruhan Model: 61.62%

Laporan Klasifikasi Detail (Precision, Recall, F1-Score):
      precision    recall  f1-score   support


   Negatif      0.60      0.96      0.74       526
    Netral      0.67      0.31      0.43       316
   Positif      1.00      0.03      0.05       143

 accuracy          0.62       985
 macro avg         0.76      0.43      0.41       985
weighted avg         0.68      0.62      0.54       985
```

Naive Bayes adalah algoritma klasifikasi yang menggunakan Teorema Bayes untuk memprediksi suatu kelas berdasarkan probabilitas kemunculan fitur. Pada tahap pemodelan digunakan algoritma Multinomial Naive Bayes karena sesuai untuk klasifikasi data teks hasil representasi TF-IDF. Model dilatih menggunakan 80% data training dan diuji menggunakan 20% data testing. Evaluasi dilakukan menggunakan metrik Accuracy, Precision, Recall, dan F1-Score untuk mengukur kemampuan model dalam mengklasifikasikan sentimen komentar ke dalam kategori Positif, Negatif, dan Netral.

Modeling Naive Bayes

```
#Visualisasi Tambahan: Confusion Matrix
cm = confusion_matrix(y_test, prediksi_nb, labels=['Positif', 'Netral', 'Negatif'])
plt.figure(figsize=(6, 4))
sns.heatmap(cm, annot=True, fmt='d', cmap='Greens',
            xticklabels=['Positif', 'Netral', 'Negatif'],
            yticklabels=['Positif', 'Netral', 'Negatif'])
plt.title('Confusion Matrix - Naive Bayes')
plt.ylabel('Label Sebenarnya (True)')
plt.xlabel('Label Tebakan Model (Predicted)')
plt.show()
```



Selain menggunakan accuracy, precision, recall, dan F1-score, evaluasi model juga dilakukan menggunakan Confusion Matrix. Visualisasi ini digunakan untuk melihat jumlah prediksi yang benar maupun salah pada masing-masing kelas sentimen sehingga dapat diketahui kategori sentimen mana yang paling mudah dan paling sulit dikenali oleh model.

Modeling Support Vektor Machine (SVM)

```
# === CRITERIA 8 & 9: ALGORITMA SUPPORT VECTOR MACHINE (SVM) ===
from sklearn.svm import SVC
from sklearn.metrics import classification_report, accuracy_score, confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt

# 1. Membangun & Melatih Algoritma SVM (Kernel Linear)
model_svm = SVC(kernel='linear', random_state=42)
model_svm.fit(X_train, y_train) # Proses Belajar dari Data Latih (80%)

# 2. Menguji Model pada Data Testing yang Belum Pernah Dilihat (20%)
prediksi_svm = model_svm.predict(X_test) # Proses Menebak

# 3. Menampilkan Metrik Kesuksesan Hasil Pengujian
print("=====")
print("  HASIL EVALUASI METRIK KESUKSESAN ALGORITMA SVM")
print("=====")
print(f"Akurasi Keseluruhan Model: {accuracy_score(y_test, prediksi_svm) * 100:.2f}%")
print("\nLaporan Klasifikasi Detail (Precision, Recall, F1-Score):")
print(classification_report(y_test, prediksi_svm))

# 4. Visualisasi Confusion Matrix SVM untuk Bahan Perbandingan
cm_svm = confusion_matrix(y_test, prediksi_svm, labels=['Positif', 'Netral', 'Negatif'])
plt.figure(figsize=(6, 4))
sns.heatmap(cm_svm, annot=True, fmt='d', cmap='Blues',
            xticklabels=['Positif', 'Netral', 'Negatif'],
            yticklabels=['Positif', 'Netral', 'Negatif'])
plt.title('Confusion Matrix - SVM')
plt.ylabel('Label Sebenarnya (True)')
plt.xlabel('Label Tebakan Model (Predicted)')
plt.show()
```


```
=====
HASIL EVALUASI METRIK KESUKSESAN ALGORITMA SVM
=====
Akurasi Keseluruhan Model: 73.71%

Laporan Klasifikasi Detail (Precision, Recall, F1-Score):
              precision    recall  f1-score   support


Negatif      0.79      0.86      0.82       526
Netral       0.65      0.71      0.68       316
Positif      0.71      0.34      0.46       143

accuracy          0.74      0.74      0.73       985
macro avg         0.72      0.64      0.66       985
weighted avg      0.74      0.74      0.73       985
```

Pada tahap pemodelan digunakan algoritma Support Vector Machine (SVM) yang diimplementasikan menggunakan class SVC dari library Scikit-Learn. SVM merupakan algoritma klasifikasi yang bekerja dengan mencari batas pemisah terbaik antar kelas sentimen. Algoritma ini dipilih karena mampu menangani data teks berdimensi tinggi hasil transformasi TF-IDF serta dikenal memiliki performa yang baik dalam tugas klasifikasi sentimen. Pada penelitian ini digunakan kernel linear karena sesuai untuk data teks dan memiliki proses komputasi yang lebih efisien. Model dilatih menggunakan 80% data training dan diuji menggunakan 20% data testing. Evaluasi dilakukan menggunakan Accuracy, Precision, Recall, F1-Score, dan Confusion Matrix untuk mengukur performa model dalam mengklasifikasikan sentimen komentar YouTube.



Modeling Support Vektor Machine (SVM)



=====

HASIL EVALUASI METRIK KESUKSESAN ALGORITMA SVM

=====

Akurasi Keseluruhan Model: 73.71%





Laporan Klasifikasi Detail (Precision, Recall, F1-Score):

	precision	recall	f1-score	support
Negatif	0.79	0.86	0.82	526
Netral	0.65	0.71	0.68	316
Positif	0.71	0.34	0.46	143
accuracy			0.74	985
macro avg	0.72	0.64	0.66	985
weighted avg	0.74	0.74	0.73	985

Berdasarkan hasil evaluasi, algoritma Support Vector Machine menghasilkan akurasi sebesar 73,71%, lebih tinggi dibandingkan Multinomial Naive Bayes yang memperoleh akurasi 61,62%. Selain itu, nilai Precision, Recall, dan F1-Score pada SVM menunjukkan performa yang lebih seimbang untuk ketiga kelas sentimen. Oleh karena itu, dapat disimpulkan bahwa algoritma SVM memberikan performa terbaik dalam mengklasifikasikan sentimen komentar YouTube pada penelitian ini.

Berdasarkan hasil evaluasi menggunakan Accuracy, Precision, Recall, dan F1-Score, model terbaik adalah Support Vector Machine (SVM) karena memperoleh akurasi tertinggi yaitu 73,71% dan memiliki kemampuan klasifikasi yang lebih seimbang dibandingkan Multinomial Naive Bayes.

Perbandingan Model Machine Learning



Kesimpulan

Berdasarkan seluruh rangkaian tahapan data science yang telah dilakukan—mulai dari ekstraksi data komentar YouTube, proses preprocessing teks, pelabelan otomatis, hingga uji pemodelan—dapat disimpulkan bahwa proyek analisis sentimen ini berjalan dengan sukses dan memberikan hasil yang objektif. Dari total data yang diuji menggunakan metode Train-Test Split (80:20), ditemukan adanya ketidakseimbangan distribusi data asli (imbalanced data) yang didominasi secara masif oleh Sentimen Negatif. Kondisi ini memberikan dampak yang signifikan terhadap performa kedua algoritma Machine Learning yang diadu.

Algoritma Multinomial Naive Bayes mencatatkan akurasi keseluruhan sebesar 62.00%. Walaupun model ini sangat sensitif dan andal dalam mendeteksi kelas mayoritas dengan nilai Recall Sentimen Negatif mencapai 96.0%, Naive Bayes terbukti mengalami bias yang parah. Model ini gagal mengenali karakteristik kata pada Sentimen Positif, terbukti dari nilai Recall-nya yang hanya menyentuh angka 3.0% karena mayoritas komentar positif terseret masuk ke dalam prediksi label negatif.

Di sisi lain, algoritma Support Vector Machine (SVM) dengan kernel linear terbukti menjadi model terbaik (best model) dalam penelitian ini. SVM sukses mencatatkan lonjakan akurasi keseluruhan hingga 73.71%. Keunggulan utama SVM terletak pada kemampuannya memisahkan dimensi fitur teks lewat batas keputusan (hyperplane) yang optimal, sehingga mampu mengklasifikasikan data secara jauh lebih cerdas dan merata. SVM tidak hanya tangguh di kelas Negatif (Recall 86.0%), tetapi juga berhasil memperbaiki kelemahan model sebelumnya dengan mendongkrak performa Sentimen Netral (Recall 71.0%) dan Sentimen Positif (Recall 34.0%).

Dengan demikian, untuk implementasi sistem analisis sentimen pada karakteristik dataset komentar YouTube berbahasa Indonesia ini, algoritma Support Vector Machine (SVM) jauh lebih direkomendasikan karena memberikan tingkat akurasi yang lebih tinggi, performa metrik evaluasi yang stabil, serta model prediksi yang jauh lebih seimbang antar kelas sentimen.

